

GPT-5.6

SOL, TERRA E LUNA

O modelo certo para cada tarefa

Um guia direto para escolher entre profundidade, equilíbrio e velocidade - sem pagar por inteligência que a tarefa não precisa.



O que você vai aprender

A diferença entre conhecer os modelos e saber escolhê-los é transformar novidade em método.

A família GPT-5.6 não foi organizada como um único modelo que tenta servir para tudo. Ela separa três níveis de capacidade: Sol, Terra e Luna. O objetivo deste guia é mostrar como essa arquitetura muda a decisão de uso.

01

A nova lógica

Geração e nível de capacidade não são a mesma coisa.

02

O que todos compartilham

Contexto, saída, conhecimento e recursos comuns.

03

Preço e disponibilidade

Onde cada modelo aparece e quanto custa na API.

04

Sol

Quando profundidade e custo do erro justificam mais inteligência.

05

Terra

O equilíbrio para o trabalho recorrente do dia a dia.

06

Luna

Velocidade e escala para tarefas simples e repetitivas.

07

Matriz de decisão

Quatro perguntas para escolher sem adivinhar.

08

Cheat sheet

Uma página para consultar antes de começar qualquer tarefa.

Não são três versões do mesmo botão

O número indica a geração. Os nomes indicam quanto poder, velocidade e custo você escolhe para a tarefa.

IDEIA CENTRAL

GPT-5.6 é a geração. Sol, Terra e Luna são níveis de capacidade que podem evoluir mantendo os mesmos papéis.

- **Geração**

O “5.6” identifica a família tecnológica. Quando a geração muda, a base de capacidades também avança.

- **Nível de capacidade**

Sol, Terra e Luna organizam a escolha entre mais profundidade, melhor equilíbrio ou menor custo por execução.

- **Decisão operacional**

A pergunta deixa de ser “qual é o modelo mais inteligente?” e passa a ser “quanto de inteligência esta tarefa realmente precisa?”.

REGRA BENDER IA

Usar sempre o modelo mais poderoso não é estratégia. É apenas pagar o preço máximo antes de entender o problema.

O que os três modelos compartilham

Antes de comparar diferenças, vale entender que Sol, Terra e Luna partem da mesma geração e de uma base técnica ampla.

1.050.000

TOKENS DE CONTEXTO

Capacidade de entrada por solicitação na API.

128.000

TOKENS DE SAÍDA

Limite máximo de resposta em uma única execução.

16 fev. 2026

CORTE DE CONHECIMENTO

Data de referência informada na documentação.

Texto + imagem

ENTRADA

Os três recebem texto e imagens como contexto.

Os três também suportam raciocínio, chamadas de função, saídas estruturadas e ferramentas como busca na web, busca em arquivos, geração de imagens, execução de código, uso do computador e MCP na Responses API.

Onde cada um está disponível

ChatGPT padrão: Sol aparece conforme plano e nível de esforço. Terra e Luna não são selecionáveis nas conversas padrão.

ChatGPT Work e Codex: planos elegíveis podem escolher Sol, Terra e Luna.

API: os três modelos estão disponíveis para desenvolvedores.

A diferença aparece em três variáveis

Profundidade, custo e volume. A escolha correta depende da combinação, não de uma classificação absoluta.

S Sol mais capacidade US\$ 5 US\$ 30 entrada / 1M tokensaída / 1M tokens Para decisões complexas, pesquisa profunda, programação avançada e tarefas em que errar custa caro.	T Terra melhor equilíbrio US\$ 2,50 US\$ 15 entrada / 1M tokensaída / 1M tokens Para trabalho diário, análise, produção de conteúdo, ferramentas internas e operações em volume moderado.	L Luna velocidade e escala US\$ 1 US\$ 6 entrada / 1M tokensaída / 1M tokens Para tarefas simples, previsíveis, repetitivas e sensíveis a custo ou latência.
---	--	---

Como interpretar os preços

Entrada é o que você envia ao modelo. Saída é o que ele produz. Os valores acima são preços oficiais por 1 milhão de tokens na API, sem incluir custos eventuais de ferramentas. Solicitações com mais de 272 mil tokens de entrada têm multiplicadores próprios.

LEITURA ESTRATÉGICA

O custo não é apenas o preço por token. Inclua também o custo de revisar erros, repetir tarefas, esperar pela resposta e corrigir decisões ruins.

SOL

Sol é o modelo para trabalhos em que a qualidade final vale mais do que economizar alguns segundos.

POSICIONAMENTO

Quando uma resposta errada pode custar horas, dinheiro ou decisões importantes, a capacidade extra deixa de ser luxo e passa a ser proteção.

Use quando

- **Problemas complexos**
Pesquisa profunda, estratégia, arquitetura de sistemas e decisões com muitas variáveis.
- **Programação avançada**
Refatorações amplas, depuração difícil, segurança e projetos de longo horizonte.
- **Entregáveis finais**
Relatórios, análises e materiais que precisam estar prontos para uso profissional.

Evite quando

- **Tarefas mecânicas**
Resumos simples, pequenas correções e classificações previsíveis.
- **Grandes volumes**
Quando cada item é barato e o custo acumulado importa mais do que a profundidade.
- **Baixo risco**
Quando um erro pequeno é fácil de detectar e corrigir automaticamente.

EXEMPLO DE FLUXO

Projeto: definir uma nova estratégia de produto.

Fluxo: reunir contexto, comparar alternativas, identificar riscos, propor cenários, testar premissas e entregar uma recomendação argumentada.

Por que Sol: o valor está na qualidade da decisão, não apenas na velocidade da resposta.

DADO DE REFERÊNCIA

Segundo dados apresentados pela OpenAI, Sol com raciocínio max alcançou 80 pontos no Artificial Analysis Coding Agent Index, acima dos 77,2 do Claude Fable 5, com menos tokens de saída, menos tempo e custo estimado menor.

TERRA

Terra é o modelo para a maior parte do trabalho real: bom raciocínio, velocidade suficiente e custo controlado.

POSICIONAMENTO

Ele faz sentido quando a tarefa exige confiança, mas não possui complexidade ou risco suficientes para justificar o modelo mais caro.

Use quando

- **Trabalho diário**

Planejamento, conteúdo, análise de documentos, apresentações e pesquisa operacional.

- **Volume moderado**

Suporte, ferramentas internas e rotinas com dezenas ou centenas de execuções.

- **Primeira escolha**

Quando você ainda não sabe se a tarefa precisa de Sol, Terra é um ponto de partida racional.

Evite quando

- **Erro muito caro**

Decisões críticas, segurança, auditorias complexas ou problemas sem critérios claros.

- **Tarefa mínima**

Extrações simples e transformações que Luna executa com qualidade suficiente.

- **Ambiguidade extrema**

Projetos que exigem longa investigação e múltiplas camadas de validação.

EXEMPLO DE FLUXO

Projeto: transformar uma reunião longa em plano de ação.

Fluxo: resumir decisões, separar responsáveis, identificar prazos, apontar dependências e criar uma versão executiva.

Por que Terra: precisa entender contexto e produzir uma saída confiável, sem exigir a capacidade máxima da família.

LUNA

Luna foi criado para tarefas em que a repetição, a latência e o custo total importam mais do que raciocínio profundo.

POSICIONAMENTO

O melhor uso de Luna não é pedir menos qualidade. É entregar tarefas com regras claras, escopo pequeno e validação objetiva.

Use quando

- **Alta repetição**
Classificar, extrair, etiquetar, reformatar e processar grandes lotes.
- **Baixa latência**
Respostas rápidas em interfaces, automações e etapas intermediárias.
- **Regras claras**
Quando o resultado correto pode ser definido com exemplos ou um esquema estruturado.

Evite quando

- **Estratégia aberta**
Problemas em que primeiro é preciso descobrir qual é a pergunta certa.
- **Código crítico**
Mudanças amplas, segurança ou depuração com consequências relevantes.
- **Entrega sem revisão**
Quando não existe validação e um erro pode chegar diretamente ao usuário final.

EXEMPLO DE FLUXO

Projeto: organizar centenas de mensagens recebidas.

Fluxo: classificar assunto, detectar urgência, extrair nome e contato, gerar uma resposta inicial curta e enviar casos incertos para revisão.

Por que Luna: o processo é padronizado, validável e sensível a custo por execução.

Quatro perguntas antes de escolher

O modelo certo aparece quando você mede a tarefa, em vez de escolher pela reputação do modelo.

1

Qual é o custo do erro?

Se errar exige horas de retrabalho, afeta clientes ou altera decisões importantes, suba para Sol.

2

Quanta ambiguidade existe?

Tarefas abertas e pouco definidas exigem mais raciocínio. Tarefas com regras claras favorecem Terra ou Luna.

3

Qual é o volume?

Quanto mais vezes o processo será executado, mais o preço por token e a latência influenciam a escolha.

4

Como o resultado será validado?

Uma boa validação permite usar modelos menores com mais segurança, porque erros podem ser detectados cedo.

HEURÍSTICA RÁPIDA

Comece com Terra. Desça para Luna quando a tarefa estiver padronizada e validada. Suba para Sol quando a ambiguidade ou o custo do erro aumentarem.

Qual modelo abrir agora?

Uma consulta rápida para escolher o nível de capacidade sem complicar.

Tarefa	Modelo	Motivo
Pesquisa profunda e estratégia	SOL	Mais capacidade para investigar, comparar e sustentar decisões.
Programação complexa ou segurança	SOL	O custo de um erro justifica raciocínio e persistência maiores.
Conteúdo, análise e trabalho diário	TERRA	Equilibra qualidade, velocidade e custo para a maioria dos fluxos.
Suporte e documentos em volume	TERRA	Mantém boa compreensão sem pagar o preço máximo por execução.
Resumo, extração e classificação	LUNA	Regras simples, grande volume e necessidade de resposta rápida.
Automação repetitiva com validação	LUNA	O custo por execução passa a ser parte central do resultado.

A COMPETÊNCIA REAL

O diferencial não está em ter acesso ao modelo mais caro. Está em decompor o trabalho, definir critérios e usar apenas a capacidade necessária em cada etapa.

A ferramenta certa no momento certo

Sol, Terra e Luna não existem para disputar qual é “o melhor”. Eles existem para tornar a escolha mais precisa.



SOL

quando a profundidade protege a qualidade da decisão.



TERRA

quando equilíbrio e consistência movem o trabalho diário.



LUNA

quando velocidade e escala definem a eficiência.

BENDER IA

Menos fascinação pela ferramenta. Mais método para transformar inteligência artificial em resultado.

Fontes oficiais e notas de leitura

Informações verificadas em 15 de julho de 2026. Preços, disponibilidade e recursos podem mudar.

Anúncio oficial do GPT-5.6

OpenAI - “GPT-5.6: inteligência de fronteira que acompanha a sua ambição”. Lançamento, posicionamento dos modelos, disponibilidade, preços e benchmarks.

GPT-5.6 no ChatGPT

OpenAI Help Center. Disponibilidade de Sol, Terra e Luna nas conversas padrão, ChatGPT Work, Codex e API.

Documentação do GPT-5.6 Sol

OpenAI API. Contexto, saída máxima, corte de conhecimento, recursos, modalidades e preços.

Documentação do GPT-5.6 Terra

OpenAI API. Posicionamento, contexto, saída máxima, recursos e preços.

Documentação do GPT-5.6 Luna

OpenAI API. Posicionamento para volume e custo, contexto, saída máxima, recursos e preços.

Nota metodológica

As recomendações de uso deste guia são uma interpretação editorial da Bender IA baseada no posicionamento oficial dos modelos. Benchmarks não substituem testes com seus próprios dados, critérios e fluxos de trabalho.